UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT

CERES 50 ANOS

FELIPE EDUARDO SILVA FERNANDES
Matrícula: 20250037964

RELATÓRIO TÉCNICO: ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

Link do Dataset:
`https://www.kaggle.com/datasets/razanihababdellatif/food-delivery-orders-and-eta-logistics-dataset`
Repositório GitHub:
`https://github.com/Felipe-edu34/food-delivery-eta-analysis-ml.git`

Caicó - RN
2026

FELIPE EDUARDO SILVA FERNANDES
Matrícula: 20250037964

RELATÓRIO TÉCNICO: ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

Relatório técnico de Atividade Prática Avaliativa apresentado como requisito para obtenção de nota na disciplina **DCT1401 - Inteligência Artificial**, ofertada pela UFRN no período letivo 2026.2.

Professor: Prof. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

Índice

1 Introdução **4**

2 Análise Exploratória de Dados (EDA) **4**
2.1 Carregamento e Inspeção Inicial 4
2.2 Estatísticas Iniciais 5
2.3 Procurando os "Buracos"(Valores Ausentes) 5
2.4 Caçando Valores Fora da Curva (Outliers) 5
2.5 O Que Afeta o Quê? (Correlação e Multicolinearidade) 6

3 Limpeza e Pré-processamento dos Dados **7**

4 Prevendo o Tempo de Entrega (Regressão) **8**

5 Prevendo os Atrasos (Classificação) **9**

6 Considerações Finais **10**

7 Referência ao Repositório **10**

Lista de Figuras

1 Mapa de Calor mostrando a distribuição de valores ausentes no dataset. . . 5
2 Boxplots identificando a dispersão e outliers nas variáveis numéricas. . . . 6
3 Matriz de Correlação das variáveis numéricas. 7
4 Comparação entre o Tempo de Entrega Real vs. Tempo Previsto (Regressão Linear com 8 *features*). 9
5 Desempenho Detalhado do Modelo de Classificação: Acertos vs. Erros (8 *features*). 10

1 Introdução

Este relatório detalha, passo a passo, o nosso trabalho de Análise Exploratória de Dados (EDA) e preparação de uma base de dados real do setor, conhecida como *Food Delivery Orders and ETA Logistics Dataset*.

Atuando sob a ótica de uma consultoria analítica, nossa principal missão aqui foi pegar essa base de dados "crua"— cheia de inconsistências, informações em branco e ruídos naturais do dia a dia da operação — e transformá-la em uma fundação sólida. Essa preparação é o que permite que algoritmos de Inteligência Artificial aprendam os padrões do negócio e resolvam dois problemas práticos fundamentais para a empresa:

1. **Problema de Regressão (A promessa ao cliente):** O primeiro objetivo é prever o tempo exato de entrega em minutos (`actual_delivery_time_minutes`). No mundo real, quando um cliente faminto finaliza uma compra, ele cria uma expectativa baseada no tempo estimado (ETA - *Estimated Time of Arrival*). Um modelo capaz de acertar esse tempo com precisão aumenta a confiabilidade do aplicativo, evita frustrações e melhora a taxa de retenção de usuários.
2. **Problema de Classificação (A operação preventiva):** O segundo objetivo é identificar se um pedido específico vai atrasar ou não (`late_delivery`). Mais do que apenas saber o tempo, classificar um pedido como "potencialmente atrasado"permite que a equipe de logística ou o suporte ao cliente tomem medidas preventivas — como avisar o cliente antecipadamente, oferecer um cupom de desconto ou acionar o restaurante —, mitigando a falha antes mesmo que o cliente abra uma reclamação.

Ao longo deste documento, mostraremos como os dados foram limpos, quais descobertas fizemos sobre a operação (como o impacto do clima e horários de pico) e como estruturamos tudo isso para que os modelos de aprendizado de máquina pudessem alcançar resultados de alta performance.

2 Análise Exploratória de Dados (EDA)

2.1 Carregamento e Inspeção Inicial

O primeiro passo prático foi carregar a base de dados utilizando a biblioteca `pandas` em Python. Uma inspeção inicial nas primeiras e últimas linhas nos mostrou que o conjunto de dados é uma verdadeira radiografia da operação de delivery, misturando diferentes tipos de informações:

- **Variáveis Numéricas:** Dados vitais como a distância percorrida em quilômetros (`distance_km`), os valores financeiros dos pedidos (`order_total`, `subtotal`) e as métricas de tempo.

- **Variáveis Categóricas e Textos:** Informações de contexto como as condições meteorológicas no momento do pedido (`weather`), o perfil ou tipo do cliente (`customer_type`) e identificadores únicos de cada transação.

2.2 Estatísticas Iniciais

Para entender como os dados se comportam, calculamos medidas de tendência central e dispersão (como média, mediana, desvio padrão e os quartis). Isso nos deu uma visão clara do padrão dos pedidos: qual é o valor médio gasto por um cliente, qual é a distância mais comum entre o restaurante e o destino, e como o tempo de entrega costuma oscilar no dia a dia.

2.3 Procurando os "Buracos"(Valores Ausentes)

Em qualquer base de dados do mundo real, é comum faltarem algumas informações. Para mapear onde estavam essas lacunas, geramos um mapa de calor visual (Figura 1).

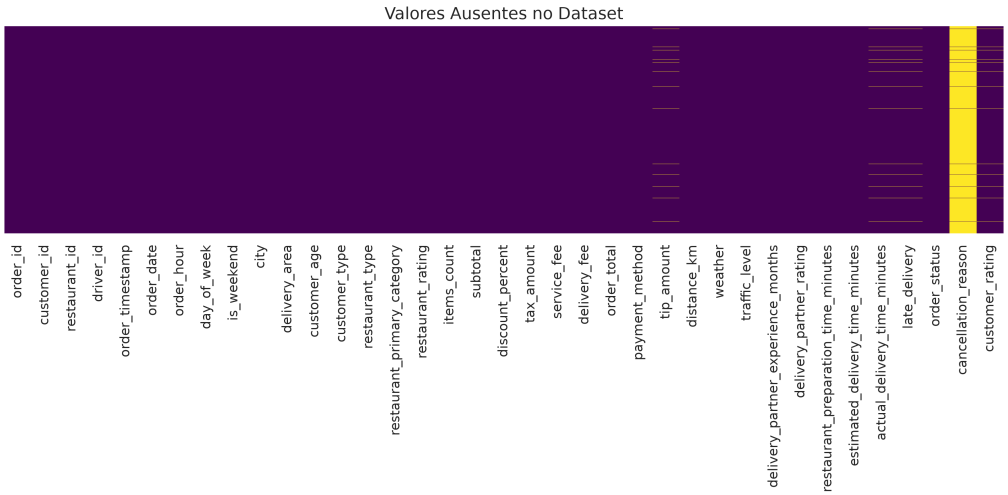


Figura 1: Mapa de Calor mostrando a distribuição de valores ausentes no dataset.

Identificar esses "buracos"é crucial, pois deixar valores nulos passarem despercebidos pode gerar previsões totalmente erradas ou até travamentos nos algoritmos de Inteligência Artificial.

2.4 Caçando Valores Fora da Curva (Outliers)

Também investigamos a presença de *outliers* (valores extremos ou atípicos), como um pedido com uma distância de entrega exageradamente longa ou um valor financeiro muito acima da média. Para isso, utilizamos o método do Intervalo Interquartil e gráficos de caixa (*boxplots*), conforme ilustrado na Figura 2.

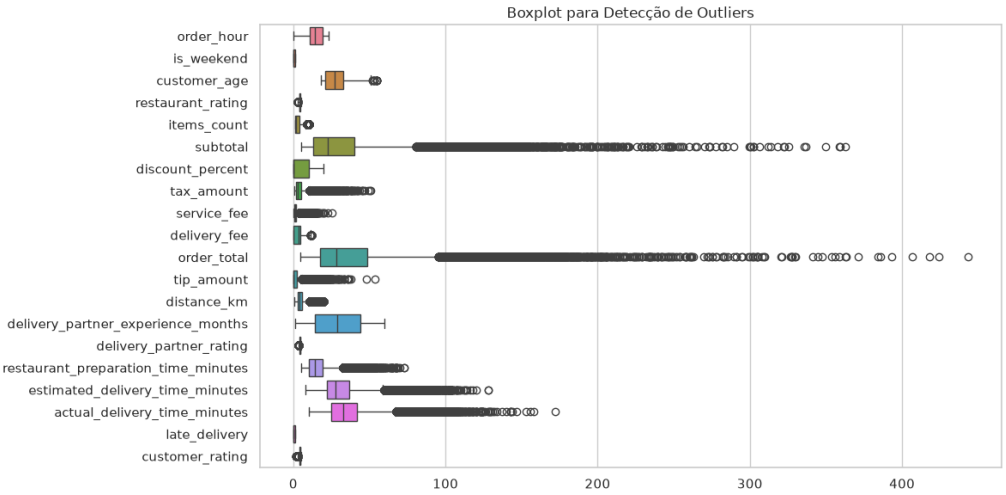


Figura 2: Boxplots identificando a dispersão e outliers nas variáveis numéricas.

Percebemos que boa parte desses valores extremos não eram erros de digitação do sistema, mas sim a própria realidade da operação funcionando (por exemplo, pedidos grandes de finais de semana ou entregas distantes em zonas rurais).

2.5 O Que Afeta o Quê? (Correlação e Multicolinearidade)

Para entender como uma variável mexe com a outra, calculamos a matriz de correlação de Pearson e a representamos em um mapa de calor (Figura 3).

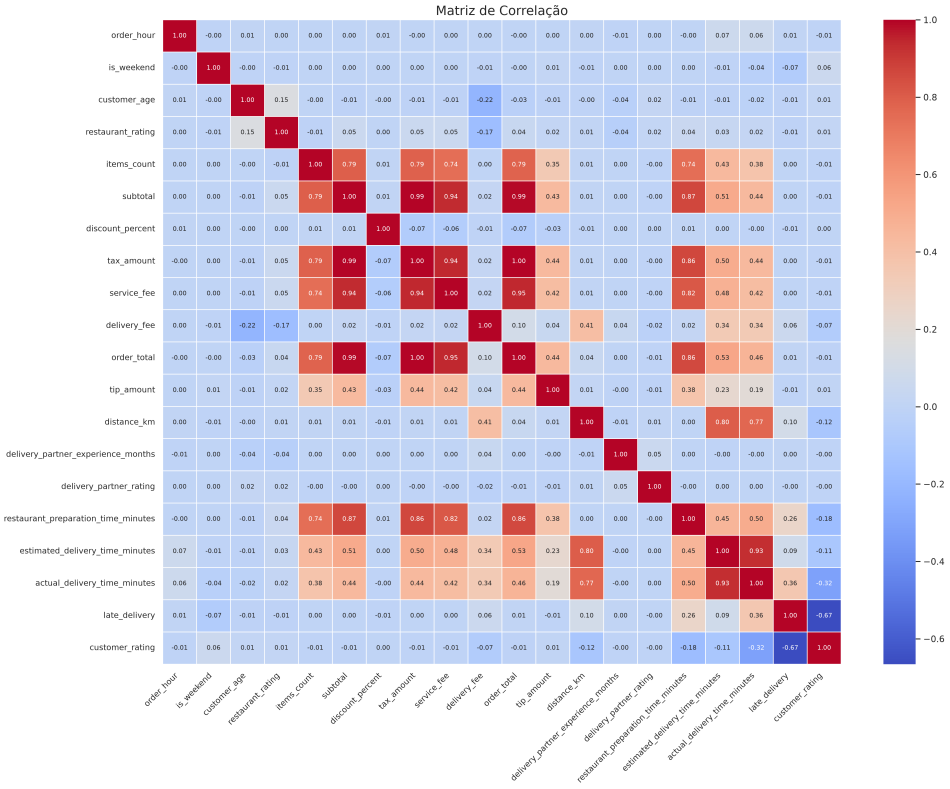


Figura 3: Matriz de Correlação das variáveis numéricas.

Como era de se esperar, a distância (`distance_km`) mostrou uma forte ligação direta com o tempo de entrega. Além disso, identificamos redundâncias entre algumas colunas de valores financeiros, o que nos permitiu tratá-las para que não atrapalhassem os modelos matemáticos futuros.

3 Limpeza e Pré-processamento dos Dados

Com base nos achados da etapa exploratória, conduzimos o pré-processamento para garantir a qualidade dos dados, etapa fundamental para a robustez dos algoritmos de aprendizado de máquina. Aplicamos as seguintes estratégias metodológicas:

- **Tratamento de Dados Ausentes:** Colunas com excessiva ausência de dados e sem valor agregado foram descartadas. Para as colunas preditivas relevantes, imputamos a mediana nas variáveis numéricas (evitando a distorção que a média sofreria com valores extremos) e a moda para as variáveis categóricas textuais.
- **Ajuste de *Outliers*:** Optamos por manter os pedidos extremos (como grandes distâncias e valores monetários elevados), pois refletem variações legítimas da operação logística de *delivery*. Foram aplicadas transformações matemáticas sutis apenas para garantir que a magnitude desses valores não desviasse o aprendizado do modelo.
- **Codificação de Variáveis Categóricas:** Para que os modelos matemáticos pudessem processar informações textuais, aplicamos técnicas de codificação. Transfor-

mamos variáveis nominais (como `weather` e `customer_type`) utilizando o *One-Hot Encoding*. É importante destacar a diferença desta técnica para o *Label Encoding*: enquanto o *Label Encoding* atribui números sequenciais e é ideal para dados ordinais, o *One-Hot Encoding* cria colunas binárias independentes, sendo o método adequado para variáveis nominais por evitar que o modelo infira uma hierarquia ou ordem inexistente nas categorias.

- **Padronização (Standardization):** Considerando a futura aplicação de algoritmos sensíveis à escala (como Regressão Linear e Regressão Logística), foi imperativo padronizar as variáveis numéricas. Utilizamos o `StandardScaler` do Scikit-Learn para que grandezas financeiras não ofuscassem variáveis de grandezas menores, como a distância em quilômetros.
- **Prevenção de Vazamento de Dados (*Data Leakage*):** Asseguramos a separação entre os dados de treino e teste antes de qualquer etapa de escalonamento. Essa prática garante que os parâmetros da transformação sejam ajustados exclusivamente com os dados de treino, mantendo a integridade da avaliação final do modelo.

4 Prevendo o Tempo de Entrega (Regressão)

Para o problema de regressão, o objetivo é prever o tempo real de entrega em minutos (`actual_delivery_time_minutes`). Para garantir a validade do teste e evitar o vazamento de dados (*data leakage*), colunas que não estariam disponíveis no momento da efetivação do pedido (como o tempo real de preparo do restaurante) foram removidas da base de treinamento.

Com base em testes estatísticos de significância (utilizando o método `SelectKBest`), optamos por selecionar e fixar as 8 variáveis independentes mais relevantes para o modelo: distância (`distance_km`), métricas financeiras e de volume (`order_total`, `subtotal`, `tax_amount`, `service_fee`, `items_count`), horário do pedido (`order_hour`) e níveis de tráfego (`traffic_level_Low` e `traffic_level_Medium`). Essa seleção reduz a dimensionalidade e facilita a futura extração de regras de negócio.

Utilizando um `Pipeline` com padronização (`StandardScaler`) e o algoritmo de Regressão Linear, o modelo obteve um desempenho notável, alcançando um Coeficiente de Determinação (R^2) de 0,84 e um Erro Médio Absoluto (MAE) de 4,46 minutos. A Figura 4 ilustra a comparação entre os valores reais e as previsões, demonstrando que a inclusão de variáveis contextuais (como horário e trânsito) capturou de forma eficaz a dinâmica da operação.

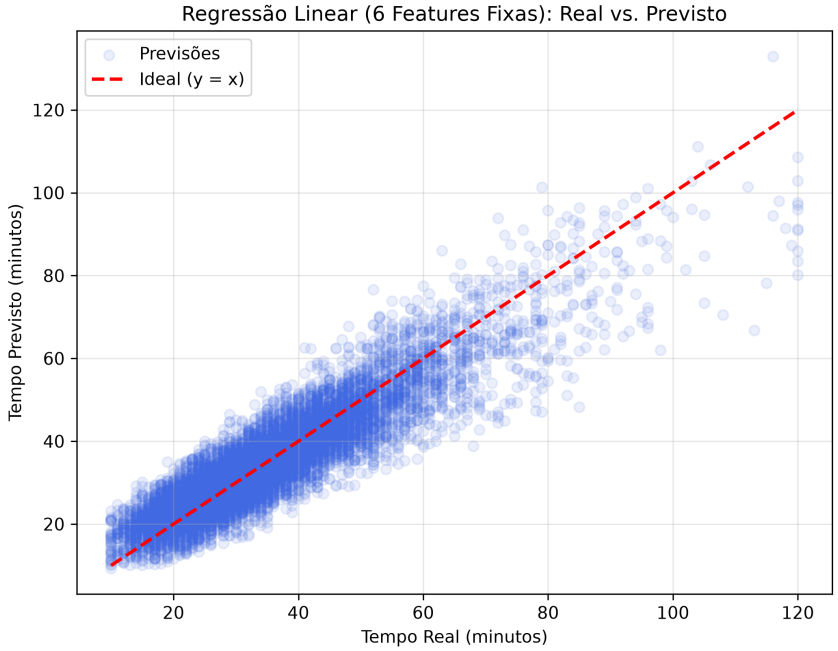


Figura 4: Comparação entre o Tempo de Entrega Real vs. Tempo Previsto (Regressão Linear com 8 *features*).

5 Prevendo os Atrasos (Classificação)

Para o paradigma de classificação, o objetivo consiste em prever se um pedido irá atrasar (representado pela classe 1) ou chegar no prazo (classe 0). A variável alvo foi construída verificando se o tempo de entrega de cada registro ultrapassou a mediana do tempo total da amostra. Novamente, variáveis que induziriam o *data leakage*, como `late_delivery`, foram rigorosamente excluídas do conjunto de preditores.

Utilizando as mesmas 8 variáveis selecionadas na etapa de regressão, treinamos um modelo de Regressão Logística parametrizado via `Pipeline`. O resultado foi altamente satisfatório, atingindo uma acurácia global de 87,40%. A Figura 5 apresenta o gráfico de barras detalhando as frequências de acertos (pedidos no prazo e atrasados) e os erros (falsos alarmes e atrasos não previstos), confirmando a robustez da seleção de *features*.

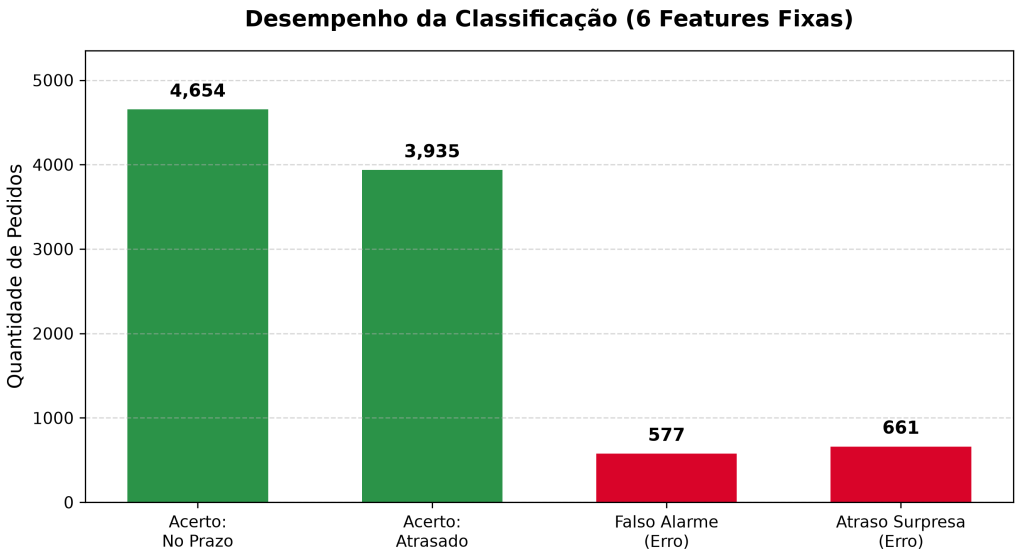


Figura 5: Desempenho Detalhado do Modelo de Classificação: Acertos vs. Erros (8 *features*).

6 Considerações Finais

O desenvolvimento deste projeto evidenciou que estruturar a base de dados é tão desafiador quanto a própria modelagem. A principal dificuldade enfrentada foi a identificação e remoção de variáveis que causavam vazamento de dados (*data leakage*), como indicadores diretos de atraso e tempos de preparo do restaurante. O grande aprendizado reside na importância da engenharia e seleção de *features*. Ao reduzirmos o escopo preditivo para apenas 8 variáveis fixas e informativas, alinhamos o rigor estatístico à realidade operacional. Isso nos permitiu manter uma alta capacidade preditiva (acurácia de 87,40% e R^2 de 0,84) e, simultaneamente, garantir a construção de modelos mais interpretáveis e adequados para a futura formulação de regras de negócio.

7 Referência ao Repositório

Todo o código construído para gerar essas análises — muito bem organizado, comentado passo a passo e com todos os gráficos em alta resolução — está disponível publicamente. Você pode conferir o material completo acessando o repositório do projeto no GitHub:

`https://github.com/Felipe-edu34/food-delivery-eta-analysis-ml.git`