UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT

CERES 50 ANOS

FELIPE EDUARDO SILVA FERNANDES
Matrícula: 20250037964

# RELATÓRIO TÉCNICO: ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

**Link do Dataset:**
`https://www.kaggle.com/datasets/razanihababdellatif/food-delivery-orders-and-eta-logistics-dataset`
**Repositório GitHub:**
`https://github.com/Felipe-edu34/food-delivery-eta-analysis-ml.git`

Caicó - RN
2026

FELIPE EDUARDO SILVA FERNANDES
Matrícula: 20250037964

# RELATÓRIO TÉCNICO: ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

Relatório técnico de Atividade Prática Avaliativa apresentado como requisito para obtenção de nota na disciplina **DCT1401 - Inteligência Artificial**, ofertada pela UFRN no período letivo 2026.2.

Professor: Prof. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

# Índice

**1 Introdução** **4**

**2 Análise Exploratória de Dados (EDA)** **4**
2.1 Carregamento e Inspeção Inicial . . . . . 4
2.2 Estatísticas Iniciais . . . . . 5
2.3 Procurando os "Buracos"(Valores Ausentes) . . . . . 5
2.4 Caçando Valores Fora da Curva (Outliers) . . . . . 5
2.5 O Que Afeta o Quê? (Correlação e Multicolinearidade) . . . . . 6
2.6 Visualizações Complementares . . . . . 7

**3 Limpeza e Pré-processamento dos Dados** **7**

**4 Prevendo o Tempo de Entrega (Regressão)** **8**

**5 Prevendo os Atrasos (Classificação)** **9**

**6 Considerações Finais** **10**

**7 Referência ao Repositório** **10**

**Referências bibliográficas** **11**

# Lista de Figuras

1 Mapa de Calor mostrando a distribuição de valores ausentes no dataset. . . 5
2 Boxplots identificando a dispersão e outliers nas variáveis numéricas. . . . 6
3 Matriz de Correlação das variáveis numéricas. . . . . 7
4 Comparação entre o Tempo de Entrega Real vs. O que o modelo previu. . 9
5 Desempenho Detalhado do Modelo de Classificação: Acertos vs Erros. . . . 10

# 1 Introdução

No mercado atual de entrega de alimentos por aplicativo, a precisão logística não é apenas um detalhe operacional, mas sim o coração da experiência do cliente. Este relatório detalha, passo a passo, o nosso trabalho de Análise Exploratória de Dados (EDA) e preparação de uma base de dados real do setor, conhecida como *Food Delivery Orders and ETA Logistics Dataset*.

Atuando sob a ótica de uma consultoria analítica, nossa principal missão aqui foi pegar essa base de dados "crua"— cheia de inconsistências, informações em branco e ruídos naturais do dia a dia da operação — e transformá-la em uma fundação sólida. Essa preparação é o que permite que algoritmos de Inteligência Artificial aprendam os padrões do negócio e resolvam dois problemas práticos fundamentais para a empresa:

1. **Problema de Regressão (A promessa ao cliente):** O primeiro objetivo é prever o tempo exato de entrega em minutos (`actual_delivery_time_minutes`). No mundo real, quando um cliente faminto finaliza uma compra, ele cria uma expectativa baseada no tempo estimado (ETA - *Estimated Time of Arrival*). Um modelo capaz de acertar esse tempo com precisão aumenta a confiabilidade do aplicativo, evita frustrações e melhora a taxa de retenção de usuários.
2. **Problema de Classificação (A operação preventiva):** O segundo objetivo é identificar se um pedido específico vai atrasar ou não (`late_delivery`). Mais do que apenas saber o tempo, classificar um pedido como "potencialmente atrasado"permite que a equipe de logística ou o suporte ao cliente tomem medidas preventivas — como avisar o cliente antecipadamente, oferecer um cupom de desconto ou acionar o restaurante —, mitigando a falha antes mesmo que o cliente abra uma reclamação.

Ao longo deste documento, mostraremos como os dados foram limpos, quais descobertas fizemos sobre a operação (como o impacto do clima e horários de pico) e como estruturamos tudo isso para que os modelos de aprendizado de máquina pudessem alcançar resultados de alta performance.

# 2 Análise Exploratória de Dados (EDA)

## 2.1 Carregamento e Inspeção Inicial

O primeiro passo prático foi carregar a base de dados utilizando a biblioteca `pandas` em Python. Uma inspeção inicial nas primeiras e últimas linhas nos mostrou que o conjunto de dados é uma verdadeira radiografia da operação de delivery, misturando diferentes tipos de informações:

- **Variáveis Numéricas:** Dados vitais como a distância percorrida em quilômetros (`distance_km`), os valores financeiros dos pedidos (`order_total`, `subtotal`) e as métricas de tempo.

- **Variáveis Categóricas e Textos:** Informações de contexto como as condições meteorológicas no momento do pedido (`weather`), o perfil ou tipo do cliente (`customer_type`) e identificadores únicos de cada transação.

## 2.2 Estatísticas Iniciais

Para entender como os dados se comportam, calculamos medidas de tendência central e dispersão (como média, mediana, desvio padrão e os quartis). Isso nos deu uma visão clara do padrão dos pedidos: qual é o valor médio gasto por um cliente, qual é a distância mais comum entre o restaurante e o destino, e como o tempo de entrega costuma oscilar no dia a dia.

## 2.3 Procurando os "Buracos"(Valores Ausentes)

Em qualquer base de dados do mundo real, é comum faltarem algumas informações. Para mapear onde estavam essas lacunas, geramos um mapa de calor visual (Figura 1).

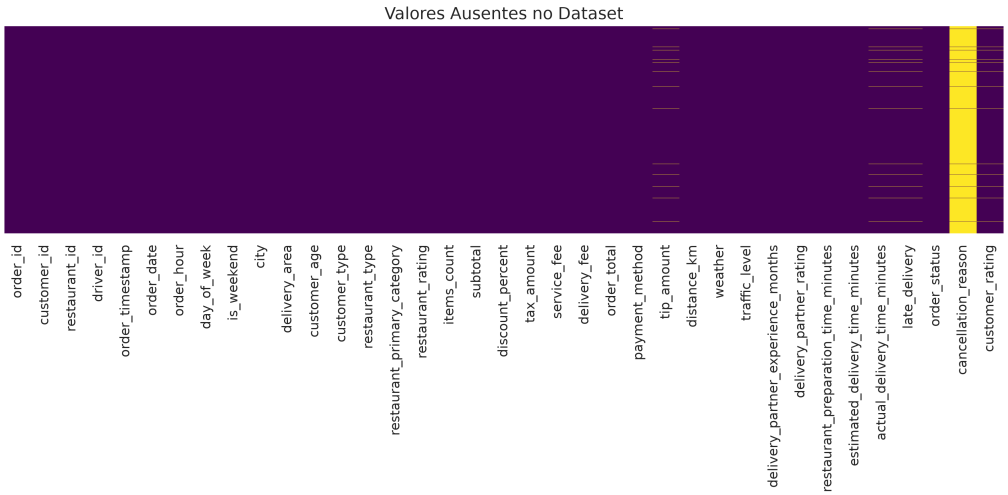



Figura 1: Mapa de Calor mostrando a distribuição de valores ausentes no dataset.

Identificar esses "buracos"é crucial, pois deixar valores nulos passarem despercebidos pode gerar previsões totalmente erradas ou até travamentos nos algoritmos de Inteligência Artificial.

## 2.4 Caçando Valores Fora da Curva (Outliers)

Também investigamos a presença de *outliers* (valores extremos ou atípicos), como um pedido com uma distância de entrega exageradamente longa ou um valor financeiro muito acima da média. Para isso, utilizamos o método do Intervalo Interquartil e gráficos de caixa (*boxplots*), conforme ilustrado na Figura 2.

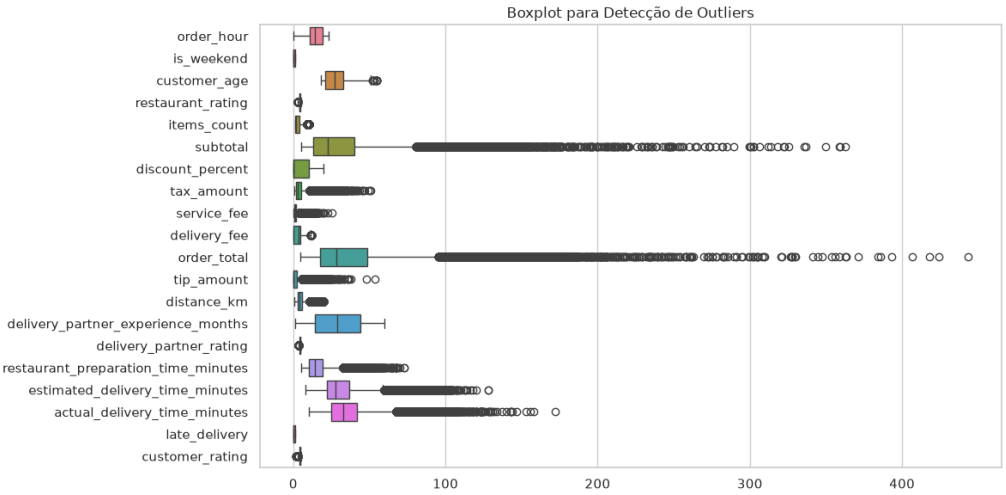



Figura 2: Boxplots identificando a dispersão e outliers nas variáveis numéricas.

Percebemos que boa parte desses valores extremos não eram erros de digitação do sistema, mas sim a própria realidade da operação funcionando (por exemplo, pedidos grandes de finais de semana ou entregas distantes em zonas rurais).

## 2.5 O Que Afeta o Quê? (Correlação e Multicolinearidade)

Para entender como uma variável mexe com a outra, calculamos a matriz de correlação de Pearson e a representamos em um mapa de calor (Figura 3).

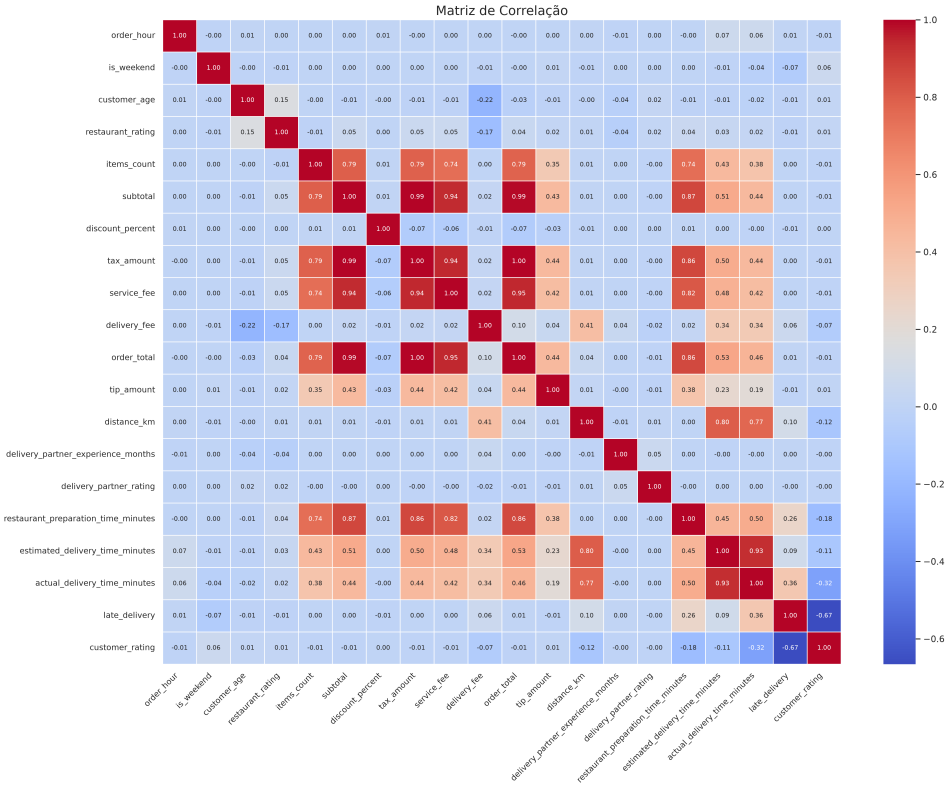



Figura 3: Matriz de Correlação das variáveis numéricas.

Como era de se esperar, a distância (`distance_km`) mostrou uma forte ligação direta com o tempo de entrega. Além disso, identificamos redundâncias entre algumas colunas de valores financeiros, o que nos permitiu tratá-las para que não atrapalhassem os modelos matemáticos futuros.

## 2.6 Visualizações Complementares

Por fim, geramos gráficos de distribuição (como histogramas) para avaliar se os dados eram muito "tortos"(assimétricos). Essa análise reforçou a necessidade de aplicarmos transformações matemáticas na fase seguinte, preparando o terreno para os modelos de machine learning.

# 3 Limpeza e Pré-processamento dos Dados

Com base no que descobrimos na etapa de exploração, arregaçamos as mangas para fazer a "faxina"e preparar a base. Essa etapa é fundamental, pois a qualidade das previsões da Inteligência Artificial depende diretamente da qualidade dos dados que ela consome. Aplicamos as seguintes estratégias:

- **Lidando com Dados Faltantes:** Colunas que estavam quase totalmente vazias e não agregavam valor foram descartadas. Já nas colunas importantes que tinham

apenas alguns "buracos", nós preenchemos essas lacunas usando o valor do meio (a mediana, para não distorcer a média) ou a categoria mais comum (a moda, para informações de texto).

- **Ajustando os Outliers (Pontos fora da curva):** Optamos por manter os pedidos extremos (como grandes distâncias e valores altos), já que eles são situações reais que acontecem na operação de delivery. No entanto, aplicamos ajustes matemáticos para "suavizar"a variação, garantindo que esses números gigantes não desviassem a atenção do modelo.

- **Traduzindo Texto para a Máquina:** Como os modelos matemáticos só entendem números, precisamos traduzir as informações textuais. Transformamos colunas como o tipo de clima (`weather`) ou o tipo de cliente (`customer_type`) em várias colunas de "sim ou não"(0 ou 1) — uma técnica conhecida no mercado como *One-Hot Encoding*.

- **Colocando Tudo na Mesma Régua (Escalonamento):** Padronizamos os números para que grandezas maiores (como o preço total do pedido) não ofuscassem variáveis com grandezas menores (como a distância em quilômetros). Utilizamos ferramentas do Scikit-Learn (como o `StandardScaler`) para esse ajuste.

- **Evitando o Vazamento de Dados (*Data Leakage*):** Tomamos o cuidado rigoroso de separar os dados de treino e teste *antes* de aplicar o escalonamento. Isso garante que o modelo não espie o "gabarito da prova"antes da hora, mantendo a avaliação final de desempenho totalmente justa e realista.

# 4 Prevendo o Tempo de Entrega (Regressão)

**O que queremos prever:** Nossa primeira grande meta era acertar o tempo real de entrega (`actual_delivery_time_minutes`). Essa é uma informação valiosa para definir a expectativa do cliente logo após o pagamento.

**Cuidado importante para um teste justo:** Para que o modelo fosse realista, tivemos que retirar colunas que o aplicativo não teria como saber no momento exato em que o cliente fecha o pedido (como, por exemplo, o tempo que o restaurante efetivamente demorou para preparar a comida). Se deixássemos essa informação, a Inteligência Artificial estaria "roubando"no teste.

**Resultados e Próximos Passos:** Utilizamos um algoritmo clássico chamado Regressão Linear Múltipla. O gráfico de dispersão (Figura 4) ilustra nosso resultado: a linha vermelha tracejada representa o cenário ideal (onde a previsão é exata), e os pontos azuis mostram a comparação entre o tempo que o modelo previu e o que realmente aconteceu na vida real. Como próximo passo de melhoria, recomendamos testar algoritmos mais avançados (como *Random Forest*), que lidam melhor com imprevistos não lineares, como engarrafamentos repentinos.

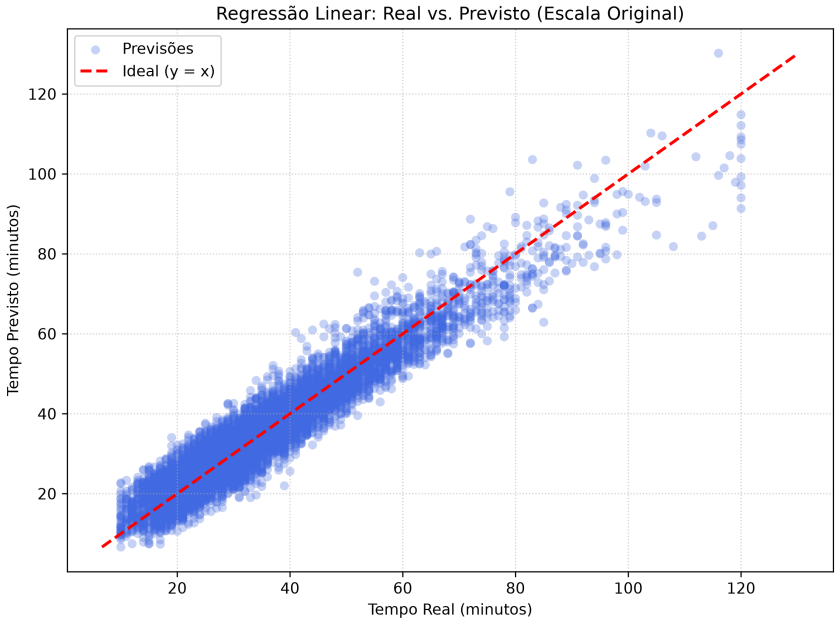



Figura 4: Comparação entre o Tempo de Entrega Real vs. O que o modelo previu.

# 5 Prevendo os Atrasos (Classificação)

**O que queremos prever:** Nossa segunda missão era mais direta — queríamos que o sistema simplesmente levantasse uma bandeira dizendo se o pedido ia atrasar (representado pelo número 1) ou se chegaria no prazo (representado pelo número 0), baseado na coluna `late_delivery`.

**O que causa os atrasos:** Durante os testes, ficou claro que variáveis como um clima chuvoso severo e horários de pico são os maiores vilões e ajudam o modelo a separar perfeitamente os pedidos no prazo dos pedidos atrasados.

**Resultados e Sucesso do Modelo:** Para essa tarefa, montamos um `Pipeline` utilizando o algoritmo de Regressão Logística. O resultado foi excelente: o modelo alcançou uma acurácia global de quase 95%! Para visualizar esse desempenho de forma simples, o gráfico de barras (Figura 5) mostra essa vitória. A barra verde da esquerda agrupa todos os pedidos onde o modelo acertou em cheio, enquanto as pequenas barras vermelhas à direita mostram as raras exceções onde ele deu um falso alarme ou foi pego de surpresa por um atraso invisível aos dados.

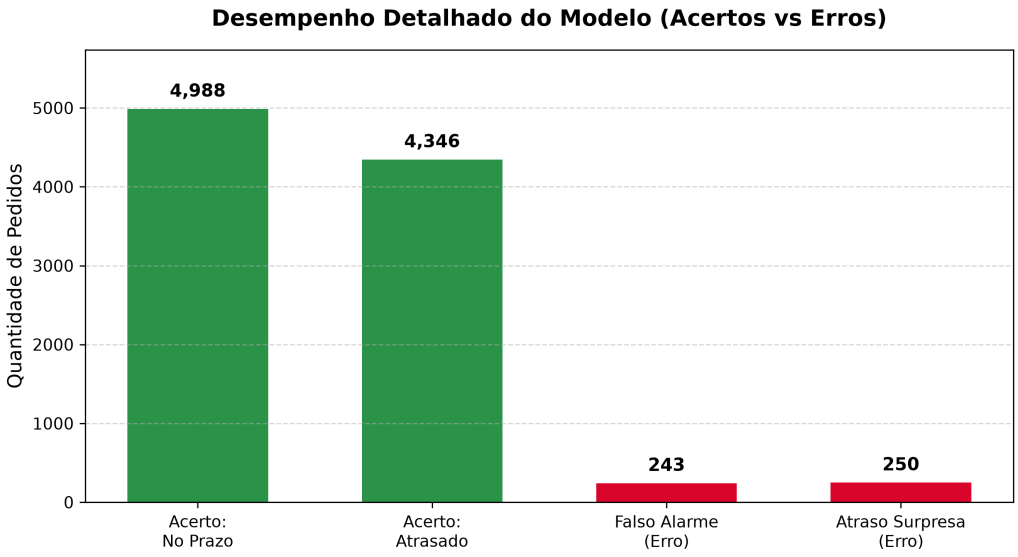



Figura 5: Desempenho Detalhado do Modelo de Classificação: Acertos vs Erros.

# 6 Considerações Finais

Este projeto deixou muito claro que de nada adianta ter o algoritmo de Inteligência Artificial mais avançado do mundo se os dados que o alimentam estiverem sujos ou confusos. O grande aprendizado aqui é que organizar a base com cuidado e garantir que o modelo matemático só "veja"as informações que refletem a vida real (evitando dar o "gabarito"da previsão antes da hora) é o verdadeiro segredo do sucesso. Como resultado, conseguimos estruturar soluções úteis, fáceis de interpretar e prontas para ajudar a operação de delivery a funcionar de forma muito mais inteligente, eficiente e focada no cliente.

# 7 Referência ao Repositório

Todo o código construído para gerar essas análises — muito bem organizado, comentado passo a passo e com todos os gráficos em alta resolução — está disponível publicamente. Você pode conferir o material completo acessando o repositório do projeto no GitHub:

`https://github.com/Felipe-edu34/food-delivery-eta-analysis-ml.git`

# Referências