UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT

CERES 50 ANOS

FELIPE EDUARDO SILVA FERNANDES
Matrícula: 20250037964

RELATÓRIO TÉCNICO: ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

Link do Dataset:
`https://www.kaggle.com/datasets/razanihababdellatif/food-delivery-orders-and-eta-logistics-dataset`
Repositório GitHub:
`https://github.com/Felipe-edu34/food-delivery-eta-analysis-ml.git`

Caicó - RN
2026

FELIPE EDUARDO SILVA FERNANDES
Matrícula: 20250037964

RELATÓRIO TÉCNICO: ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

Relatório técnico de Atividade Prática Avaliativa apresentado como requisito para obtenção de nota na disciplina **DCT1401 - Inteligência Artificial**, ofertada pela UFRN no período letivo 2026.2.

Professor: Prof. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

Índice

1 Introdução **4**

2 Análise Exploratória (EDA) **4**
2.1 Estatísticas e Qualidade dos Dados 4
2.2 Detecção de Outliers e Correlação 4

3 Limpeza e Pré-processamento **6**

4 Percepções para Regressão **6**

5 Percepções para Classificação **7**

6 Considerações Finais **8**

7 Referência ao Repositório **8**

Referências bibliográficas **9**

Lista de Figuras

1 Mapa de Calor dos Valores Ausentes. 4
2 Boxplot identificando dispersão e outliers nas variáveis numéricas. 5
3 Matriz de Correlação das variáveis numéricas. 5
4 Dispersão da Regressão Linear: Tempo Real vs Previsto. 7
5 Matriz de Confusão do modelo preditivo de atrasos. 8

1 Introdução

Este relatório descreve o processo de Análise Exploratória de Dados (EDA) e pré-processamento de um conjunto de dados do setor de delivery de comida. O objetivo do trabalho, simulando uma demanda de consultoria analítica, é preparar o dataset para a aplicação de modelos de Machine Learning. A base de dados contém informações operacionais como tempos de preparo, distância, clima e custos dos pedidos. A análise visa sustentar a modelagem de dois problemas distintos: um de regressão (para prever o tempo exato de entrega) e um de classificação (para prever a ocorrência de atrasos).

2 Análise Exploratória (EDA)

2.1 Estatísticas e Qualidade dos Dados

O dataset possui um volume robusto de registros. A inspeção inicial revelou a presença de variáveis categóricas (como *weather* e *customer_type*) e numéricas (como *distance_km*). Foi gerado um mapa de calor (Figura 1) que confirmou a integridade da maior parte da base, com valores ausentes concentrados em colunas específicas, requerendo tratamento adequado.

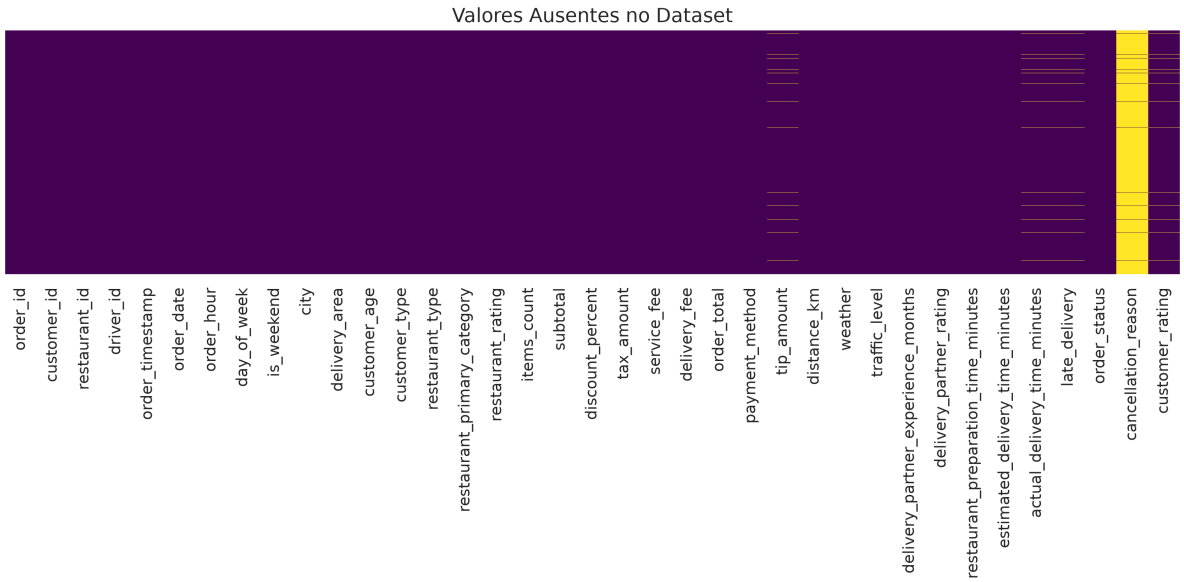


Figura 1: Mapa de Calor dos Valores Ausentes.

2.2 Detecção de Outliers e Correlação

Através de boxplots divididos em subplots por categoria (financeiro, tempos e distâncias) (Figura 2), contornou-se a distorção de escala e identificou-se a presença de outliers naturais, como pedidos de altíssimo valor (*order_total*). A matriz de correlação (Figura

3) foi otimizada para remover redundâncias financeiras e revelou a forte associação entre a distância e a variável alvo de tempo de entrega.

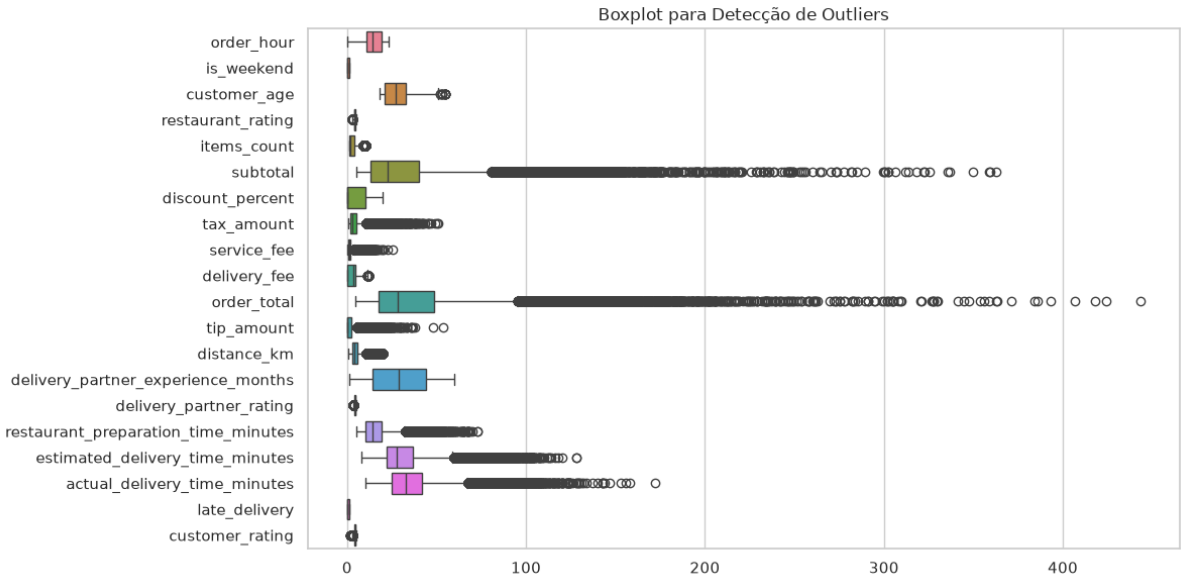


Figura 2: Boxplot identificando dispersão e outliers nas variáveis numéricas.

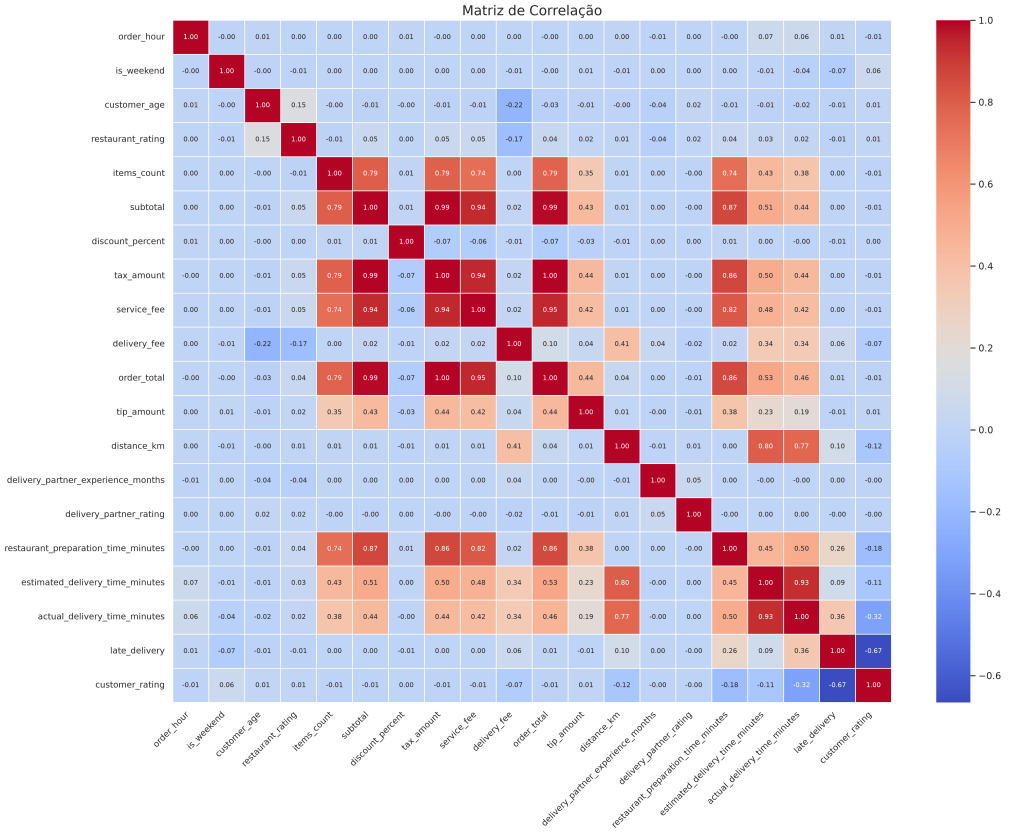


Figura 3: Matriz de Correlação das variáveis numéricas.

3 Limpeza e Pré-processamento

Para garantir a qualidade da modelagem, as seguintes técnicas foram aplicadas:

- **Tratamento de Nulos:** Colunas com excesso de nulos foram descartadas. Linhas com valores ausentes críticos para a previsão foram removidas.
- **Codificação de Categóricas:** Variáveis como clima passaram por *One-Hot Encoding*, transformando texto em colunas binárias numéricas.
- **Remoção de Identificadores:** Colunas como *order_id* foram removidas para não causar ruído no aprendizado.
- **Normalização e Validação:** Aplicação de escalonamento (`MinMaxScaler` e `StandardScaler`) utilizando o isolamento de transformadores e `Pipeline`. O ajuste (*fit*) foi feito estritamente nos dados de treinamento para evitar vazamento de dados (*data leakage*) e garantir a integridade estatística do conjunto de teste.

4 Percepções para Regressão

Variável Alvo: A variável escolhida foi *actual_delivery_time_minutes*, um número contínuo adequado para medir o erro em minutos.
Análise de Features: A variável de distância espacial (*distance_km*) e subtotal demonstraram o maior peso preditivo físico e financeiro. Um passo crucial foi a identificação e remoção de vazamento de dados (*data leakage*) de variáveis "do futuro"— como a estimativa de entrega e o tempo real de preparo no restaurante, que só são conhecidos após o fato.
Recomendações e Resultados: Utilizou-se a Regressão Linear Múltipla (Figura 4). Para garantir a interpretabilidade de negócio, a escala normalizada foi revertida (usando `inverse_transform`), permitindo avaliar o Erro Médio Absoluto (MAE) em minutos reais, resultando em um modelo realista e aplicável ao momento do *checkout* do pedido.

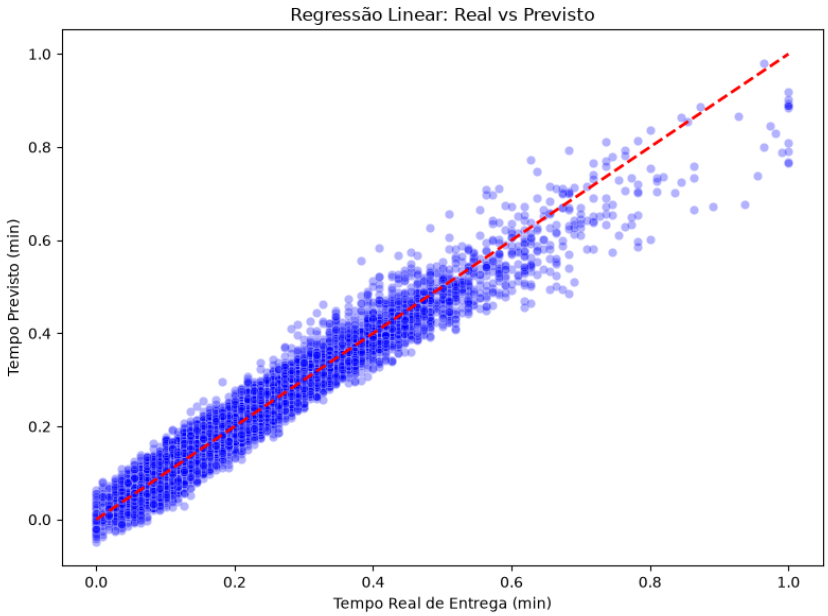


Figura 4: Dispersão da Regressão Linear: Tempo Real vs Previsto.

5 Percepções para Classificação

Variável Alvo: *late_ delivery*, categórica binária (0 = no prazo, 1 = atrasado).
Análise de Features: Variáveis climáticas (ex: tempestades) e dias de pico influenciaram a ocorrência de atrasos. A modelagem foi construída garantindo que nenhuma variável de tempo ocorrida após a compra alimentasse o algoritmo.
Recomendações e Resultados: Para lidar com a classificação de forma robusta, foi estruturado um `Pipeline` com `StandardScaler` e Regressão Logística. O modelo obteve excelente desempenho preditivo, alcançando uma Acurácia de 94,98%. A Matriz de Confusão (Figura 5) e o relatório de classificação demonstraram métricas de *Precision*, *Recall* e *F1-Score* de 0,95 para ambas as classes, indicando um sistema altamente equilibrado e confiável na identificação de entregas que extrapolarão o prazo.

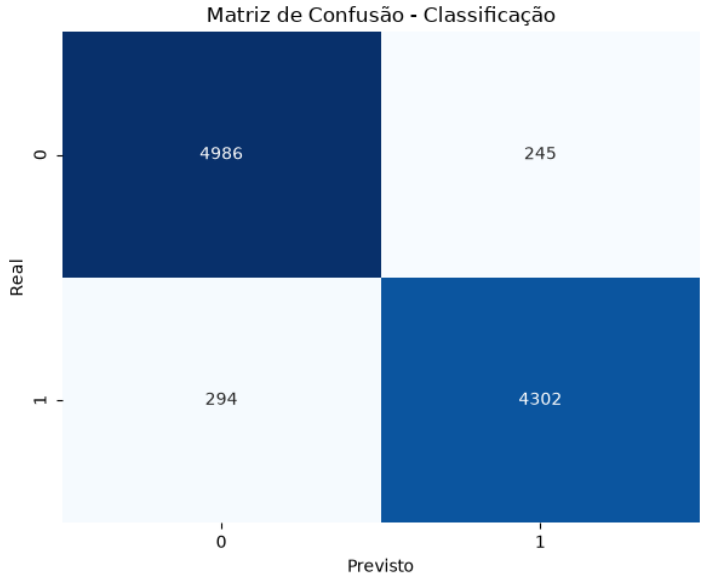


Figura 5: Matriz de Confusão do modelo preditivo de atrasos.

6 Considerações Finais

O trabalho demonstrou a importância da preparação dos dados. A maior dificuldade consistiu em isolar o *data leakage*. O aprendizado central é a necessidade de alinhar o entendimento do negócio logístico com as técnicas matemáticas de pré-processamento.

7 Referência ao Repositório

O código fonte, estruturado de forma modular (pastas `src/` e `notebooks/`), está disponível em:
Acesso ao Repositório:
`https://github.com/Felipe-edu34/food-delivery-eta-analysis-ml.git`

Referências